

多変量解析


北海道大学大学院農学研究院

(兼) 数理・データサイエンス

教育研究センター


佐藤昌直

RNA-seq解析における 多変量解析の位置付け



モチベーション:

多次元データを人間が解釈できるように補助する



3遺伝子測定データ → RNA-seq: 数千-数万次元

モチベーション:


多次元データを人間が解釈できるように補助する

→ 高次元データを低次元で表現し
可視化する

→ 高次元データを統計量で表現し
特徴を選択する/
優先順位をつける

高次元（多パラメーター）データの 認識における問題をどう扱うか？

クラスタリングによる分類



14 プロファイル
→ 3 クラスタ

データの確認：目視

Sato_A_thaliana-P_syringae_avrRpt2_6h_expRatio_small.txt


をエクセルで開いて見えます。

データの確認：Rでの可視化

```
inputMatrix <- read.delim(  
  file.path("~/Desktop/gitc/data/MS/dataset/",  
            "sato_et_al_2010_plos_pathog_exp-ratio_small.tsv"  
),  
  header=TRUE,  
  row.names=1  
)  
str(inputMatrix)      # データの構造を確認する  
image(t(inputMatrix)) # カラーコードで行列データをそのまま可視化  
  
heatmap(as.matrix(inputMatrix)) # 階層クラスタリングとヒートマップ
```

ex601-0


Rは簡単に「何か」を出力してくれる！



統計の基礎知識とRへの正しい命令が必要


高次元（多パラメーター）データの 認識における問題をどう扱うか？

クラスタリングによる分類



14 プロファイル
→ 3 クラスタ


人間は低次元データだと パターン認識するのは得意



コンピューターにどうデータを渡せば この問題をどう扱えるか？

人間

遺伝子発現プロ
ファイルの比較




問題定義の変換


(生物学の問題を数学の問題に置き換える)

計算機


ベクトル等の
数学で扱える
特徴量を
用いた計算



7次元の遺伝子発現データセット




7遺伝子の発現プロファイル間の類似性は 7次元空間での距離によって決まる




距離の基準を何にするか

距離尺度

ユークリッド距離




Uncentered Pearson correlation coefficient = $\cos\theta$



相関係数



Pearson correlation coefficient



距離尺度の違い→解析視点の違い:

遺伝子発現プロファイルの形と大きさ

- 形: ベクトルの方向
- 大きさ: ベクトルのサイズ



解析視点の決め方:


どの距離尺度を使うか？

- どんなプロファイルを同じプロファイルと定義するか？ 比較したいのは
 - 発現変動の大きさ → ユークリッド距離
 - 発現パターン → コサイン係・相関係数
- 👉 これらを理解するために距離尺度計算の内容を次に確認します


距離尺度計算の基本要素:

- **Centering:** 平均値をゼロにする
- **Scaling:** ベクトルの大きさを1にする


Centering




これらはcentering後は
全く同じプロファイルになる




Scaling




これらはscaling後は
全く同じプロファイルになる



これらはcentering, scaling後は
全く同じプロファイルになる



アルゴリズムに注目: 相関係数の場合



$$(a_1 - \bar{a})(b_1 - \bar{b}) + (a_2 - \bar{a})(b_2 - \bar{b}) + (a_3 - \bar{a})(b_3 - \bar{b})$$

$$\frac{(a_1 - \bar{a})(b_1 - \bar{b}) + (a_2 - \bar{a})(b_2 - \bar{b}) + (a_3 - \bar{a})(b_3 - \bar{b})}{\sqrt{(a_1 - \bar{a})^2 + (a_2 - \bar{a})^2 + (a_3 - \bar{a})^2} \sqrt{(b_1 - \bar{b})^2 + (b_2 - \bar{b})^2 + (b_3 - \bar{b})^2}}$$

センタリング

スケーリング

距離尺度選択における注意点

方法依存的に抽出される特徴:

どのような特徴を認識したいのか/
しているのか意識すること

- 処理間の変動の大きさ: ユークリッド距離
- 処理間のパターンの違い: コサイン係数
- パターンを比較
 - 基準サンプルあり: コサイン係数
 - 基準サンプルなし: 相関係数

様々な“距離”: Jaccard indexes

定義式

$$J(A, B) = |A \cap B| / |A \cup B|$$


例) DNA k-mer

A = {ATG, TGC, GCC, CCA}

B = {TGC, GCC, CCT}

- 共通部分 = { TGC, GCC } → 2
- 和集合 = {ATG, TGC, GCC, CCA, CCT} → 5

$$J(A, B) = 2 / 5 = \mathbf{0.4}$$



例) メタゲノム解析

様々な“距離”: レーベンシュテイン距離

定義式

2つの配列の違いを表す指標。

一方を他方に変換する1文字の置換・挿入・削除の最小回数

例) DNA配列

置換: ATGCC → ATGAC (編集回数 = 1)

挿入: ATGC → ATGAC (編集回数 = 1)

削除: ATGCC → ATGC (編集回数 = 1)

例) DNAバーコード/インデックス設計

多変量解析の実際


教師有るか無しか

(supervised or unsupervised) ?

- 事前情報、前提はあるか？
- ある場合はk-means法などの利用を検討

どのような距離行列を使うか？

階層クラスタリング [統計学入門]



利点

- 簡便・直感的な可視化
- デンドログラム長でのクラスター比較

欠点

- サンプル・手順依存的
- 1つの距離を指標

主成分分析

Principal component analysis

主成分分析とは？

モチベーション:


多次元データ（多数の遺伝子もしくは多数のサンプル）に含まれる特徴を

- ・ 大きなものから抽出して**新たな軸**を作り
- ・ **情報量の大きな低次元**でデータを可視化する


→ **人間が**新たな解釈を与える

階層クラスタリング と PCAの対比：


階層クラスタリングではプロファイル間の類似性は空間での**1つの距離**によって決まる




PCAは何をするのか？



PCAは何をするのか？



PCAは何をするのか？



PCAの概略(2次元)

1. 各サンプル (1.. n) の観察値(x_n, y_n)を

$$\begin{aligned} u_n &= a_1 x_n + b_1 y_n \\ v_n &= a_2 x_n + b_2 y_n \end{aligned}$$

とおく

足し算→線形


2. $a^2 + b^2 = 1$, u と v の相関係数0という制約の下でこれを解いて a_n, b_n を求める。

PCAで得られる重要な統計量

- 寄与率
- 因子負荷量
- 主成分得点


寄与率

- 各主成分が説明する分散の割合




負荷量 loadings

- 得られた主成分と元データのパラメーターの相関
- 各パラメーターがもとのデータの情報をどれだけ有するか



主成分得点 scores


- 各パラメーター
(遺伝子) の値
を各主成分につ
いて標準化した
統計量



標準化: 平均0, SD=1

biplot:

因子負荷量と
主成分得点を
同時に可視化



```
source("~/Desktop/gitc/data/MS/dataset/multivariate_analysis_source.R")
PCAResults <- PCA(inputMatrix)
biplot(PCAResults$scores[,1:2], PCAResults$loadings[,1:2],
       col=c("grey", "black"), cex=c(0.25,0.75))
```

ex601-3で着
目するPCを決めて可
視化してください

主成分分析(まとめ)

- 主成分分析はデータの分散を説明する新たな軸を計算する方法
 - 寄与率
 - 因子負荷量
 - 主成分得点

多次元尺度構成法

Multi-dimensional scaling(MDS),
Principal coordinate analysis


多次元尺度構成法とは？

モチベーション:


**多次元での各サンプル間の距離を保持して
低次元で表現する（多様体学習の1つ）**

⇔ 高次元の距離を低次元に圧縮するため
軸に意味がない


PCAが考慮する距離




MDSが考慮する距離




サンプル間の距離をまず計算する



この定理はサンプル*i,j*に対し、どこを原点（点*k*）としても成り立つ




この定理はサンプル*i,j*に対し、どこを原点（点*k*）としても成り立つ




$$d_{ij}^2 = d_{ik}^2 + d_{jk}^2 - 2d_{ik}d_{jk} \cos \theta$$


MDSとPCAの違い



Raw data (3 genes)



MDS (2D)



PCA (2 PCs)

PCA/MDSのまとめ

データがもつ類似性を低次元で表現し、評価・可視化する

	PCA	MDS
軸に意味がある	Yes	No

サンプルの総体的な位置関係を保持するか？

データが線形である場合	Yes	Yes/No
データが非線形である場合	No	Yes/No PCAよりも局所的な類似関係をうまく表現しうる

- **重心の置き方に違い:** 入力データをどのように前処理するか

多様体学習: 非線形データの多変量解析

モチベーション:

非線形のデータ構造を低次元に圧縮して表現する

- Locally linear embedding
 - Isomap
 - t-SNE
 - UMAP
- } NGS解析にあまり使われないので
割愛するが、IsomapはMDSの
延長として勉強するのに有用

注意点: 局所 (サンプル間) の距離・関係を重視し、
全体の距離は犠牲にしている

t-SNE, UMAP


モチベーション：

非線形のデータ構造を低次元に圧縮して表現する


- 多様な状態のサンプル間の関係性、クラスターを特定する
- single cell omicsデータ解析におけるMDSの立ち位置

t-SNE, UMAP アルゴリズム概略

1. サンプル間の距離を計算
2. 高次元でのサンプル間距離が低次元でも同様になるよう調整 (embedding, 埋め込み)
 1. t-SNE: t-分布を使って距離を調整
 2. UMAP: グラフ解析を利用




Step 1: Compute a graphical representation of the dataset



Step 2 (non-parametric): Learn an embedding that preserves the structure of the graph


Sainberg et al. (2009)
[arXiv:2009.12981](https://arxiv.org/abs/2009.12981)

人工非線形データの多変量解析







仮定：3遺伝子（次元）データ

- 時間に変化する細胞集団2つ
- ランダムな状態の細胞集団1つ







- 分布：2次元ではスイスロール
- 残りの1次元: 初めは多様性が低い

PCA, MDS, t-SNE, UMAP






t-SNE/UMAPの特徴





t-SNE/UMAPの特徴

- 近傍のサンプルのクラスター化
- 実空間での距離・サンプル分布は反映しない
 - クラスターサイズは関係ない



t-SNE/UMAPの違い

- クラスターの分離: UMAP > t-SNE
- 速度: UMAP < t-SNE
- t-SNEは結果が必ず同じ結果になるとは限らない（収束していない可能性がある）




多様体学習: 非線形データの多変量解析

- t-SNE
- UMAP
 - : 非線形高次元データのクラスタリングが可能

注意点: 局所（サンプル間）の距離・関係を重視し、
全体の距離は犠牲にしていることを念頭に
入れて結果を解釈する必要性あり

多変量解析をもう一歩進めて: 入力データは何を使うか?



多変量解析をもう一歩進めて:

人間の解釈をアシストするデータ取得を心がける

多変量解析の枠組み

多次元（例: 多パラメーター）を
より少ない指標を使って理解する



N個のサンプルをM個 ($M < N$)の
グループに分類する

→ 人間が新たな解釈を与える

コントロール、
指標サンプルは
含まれるか？

今回の内容で扱わなかった重要項目

- 教師あり多変量解析
 - k-means法
- 非線形多変量解析・次元圧縮の詳細

連絡：コピーライト

コピーライトは佐藤にあります。

資料内容の使用については下記連絡先までご連絡ください。

- satox@agr.hokudai.ac.jp